

```

1  # -*- coding: utf-8 -*-
2  from pathlib import Path
3  import re
4
5  def getResults(file):
6      """Prend en entrée un fichier de résultats et retourne une liste contenant les
        différents résultats"""
7      data = file.read()
8      data = re.sub(r"\n",r"",data)
9      results = re.findall(r"<result>.*?</result>",data)
10     return results
11
12 def getTag(result,tag):
13     """Prend en entrée un résultat (un élément de la liste de résultats) et un nom
        de balise à rechercher et retourne le résultat pertinent contenu entre les
        balises souhaitées"""
14     resu = re.findall(f"<{tag}>(.*?)</{tag}>",result)
15     return resu
16
17 #Le script est commenté entièrement au début, puis seulement aux endroits où il y a
    des choses nouvelles car le principe reste toujours le même : on parse des fichiers
    de résultats en prenant en compte leur spécificité pour obtenir des fichiers
    contenant des Google arrays facilement copiables pour les insérer dans des graphiques.
18
19
20 #répertoire contenant les fichiers txt de résultats des requêtes XQuery
21 directory = Path("../requetes")
22 #répertoire de sortie qui contiendra les google arrays sous forme de fichiers txt
23 outDir = Path("../requetes_arrays")
24
25 #on parcourt le répertoire et on va faire des tests pour chaque sous-répertoire
26 for child in directory.iterdir():
27     if child.is_dir():
28         if child.match("*basic"):
29             #on va parcourir tous les fichiers résultats du sous-répertoire "basic"
30             for subchild in child.iterdir():
31                 #nom du fichier de sortie qui contiendra les résultats
32                 #sous forme de Google array
33                 nameOut = "basic/" + subchild.stem + "_array.txt"
34                 #on crée le chemin vers ce nouveau fichier
35                 pathToF = outDir.joinpath(nameOut)
36                 if subchild.match("*annee_r.txt"):
37                     #on ouvre le premier fichier de résultats et on ouvre le fichier
38                     #de sortie
39                     with open(subchild,"r",encoding="utf-8") as file, open(pathToF,
40                                     "a",encoding="utf8") as out:
41                         #on récupère les résultats
42                         results = getResults(file)
43                         #on écrit les en-têtes
44                         out.write('["Année", "Nombre de jeux"],\n')
45                         #on parcourt les résultats pour récupérer toutes les
46                         informations
47                         #que l'on écrit au fur et à mesure dans la sortie
48                         #sous la forme souhaitée pour le graphique ensuite
49                         for res in results:
50                             year = getTag(res,"year")
51                             count = getTag(res,"count")
52                             row = f'["{year[0]}", {count[0]}],\n'
53                             out.write(row)
54                             out.write("\n")
55                         print(f'Google array in "{nameOut}" generated ! \n')
56                         print("-----")
57
58                 if subchild.match("*decennies_r.txt"):
59                     with open(subchild,"r",encoding="utf-8") as file, open(pathToF,"a",
60                                     ,encoding="utf8") as out:
61                         #ici on va faire attention de récupérer tous les genres pour
62                         les classer par ordre alphabétique
63                         data = file.read()
64                         data = re.sub(r"\n",r"",data)
65                         listeGenre = getTag(data, "genre")
66                         listeGenre = list(dict.fromkeys(listeGenre))

```

```

62     listeGenre.sort()
63     sep = ", "
64     #on écrit l'en-tête avec les genres séparés par des virgules
    et entourés de guillemets
65     out.write(f'["Décennies", "{sep.join(listeGenre)}"],\n')
66     results = re.findall(r"<result>.*?</result>",data)
67     dicoR = {}
68     #on va récupérer les différentes informations des résultats
69     #et on va remplir un dictionnaire pour tout classer
70     for res in results:
71         year = getTag(res,"year")
72         count = getTag(res,"count")
73         genre = getTag(res,"genre")
74         if dicoR.get(genre[0]) is not None:
75             dicoR[genre[0]].append((year[0],str(count[0])))
76         else:
77             dicoR[genre[0]] = [(year[0],str(count[0]))]
78     liste1990 = []
79     liste2000 = []
80     liste2010 = []
81     #on va parcourir la liste des genres pour avoir le même ordre
    pour les trois décennies
82     #on connaît nos données donc on sait comment les gérer
83     #on gère les cas où il n'y a pas de données pour certains
    genres et certaines décennies
84     for genre in listeGenre:
85         result = dicoR.get(genre)
86         if len(result)==3:
87             liste1990.append(result[0][1])
88             liste2000.append(result[1][1])
89             liste2010.append(result[2][1])
90         elif len(result)==2:
91             liste1990.append("0")
92             liste2000.append(result[0][1])
93             liste2010.append(result[1][1])
94         else:
95             liste1990.append("0")
96             liste2000.append("0")
97             liste2010.append(result[0][1])
98     #on écrit tout dans la sortie avec les différentes listes de
    résultats par décennies dans le même ordre que l'en-tête
99     sep = ", "
100     row1 = f'["1990-1999", {sep.join(liste1990)}], '
101     out.write(row1)
102     out.write("\n")
103     row2 = f'["2000-2009", {sep.join(liste2000)}], '
104     out.write(row2)
105     out.write("\n")
106     row3 = f'["2010-2019", {sep.join(liste2010)}], '
107     out.write(row3)
108     out.write("\n")
109     print(f'Google array in "{nameOut}" generated ! \n')
110     print("-----")
111
112     #les prochains traitements de fichiers résultats suivent la même
    logique que la précédente
113     if subchild.match("*genre_r.txt"):
114         with open(subchild,"r",encoding="utf-8") as file, open(pathToF,
            "a",encoding="utf8") as out:
115             results = getResults(file)
116             out.write('["Genre", "Nombre de jeux"],\n')
117             for res in results:
118                 genre = getTag(res,"genre")
119                 count = getTag(res,"count")
120                 row = f'["{genre[0]}", {count[0]}], '
121                 out.write(row)
122                 out.write("\n")
123             print(f'Google array in "{nameOut}" generated ! \n')
124             print("-----")
125
126     if subchild.match("*platform_r.txt"):
127         with open(subchild,"r",encoding="utf-8") as file, open(pathToF,

```



```

193         out.write(row)
194         out.write("\n")
195     print(f'Google array in "{nameOut}" generated ! \n')
196     print("-----")
197
198     if subchild.match("*ventes_zones_r.txt"):
199         with open(subchild,"r",encoding="utf-8") as file, open(pathToF,
200             "a",encoding="utf8") as out:
201             results = getResults(file)
202             out.write('["Pays", "Ventes (en millions)", "Continent"],\n')
203             for res in results:
204                 total_usa = getTag(res,"total_sales_usa")
205                 total_euro = getTag(res,"total_sales_eur")
206                 total_jap = getTag(res,"total_sales_jap")
207
208                 #on fait des listes de pays par continent car pour le
209                 #graphique sous forme de carte, on ne peut pas mélanger des
210                 #continents (Amérique du Nord et Europe) avec un pays
211                 #(Japon). Il est donc nécessaire de faire des listes de pays
212                 #afin de faire une carte propre où tout sera bien représenté
213
214                 america = ["United States","Canada","Mexico"]
215                 europe = ["France","Germany","Spain","Portugal","Italy",
216                     "United Kingdom","Ireland","Poland","Russia","Ukraine",
217                     "Sweden","Norway","Finland","Romania","Belarus","Kazakhstan",
218                     "Greece","Bulgaria","Iceland","Hungary","Austria","Czech
219                     Republic","Serbia","Lithuania","Latvia","Croatia","Bosnia
220                     and Herzegovina","Slovakia","Estonia","Denmark","Switzerland"
221                     ,"Netherlands","Moldova","Belgium","Armenia","Albania",
222                     "North Macedonia","Turkey","Slovenia","Montenegro","Kosovo",
223                     "Cyprus","Azerbaijan","Luxembourg","Georgia","Andorra",
224                     "Malta","Liechtenstein","San Marino","Monaco","Vatican City"]
225
226                 #pour chaque pays, on va écrire une ligne avec le bon total
227                 #et le bon continent
228                 for country in america:
229                     row = f'["{country}", {total_usa[0]}, "Amérique du
230                         Nord"], '
231                     out.write(row)
232                     out.write("\n")
233
234                 for country in europe:
235                     row = f'["{country}", {total_euro[0]}, "Europe"], '
236                     out.write(row)
237                     out.write("\n")
238
239                 row = f'["Japan", {total_jap[0]}, "Japon"], '
240                 out.write(row)
241                 out.write("\n")
242                 print(f'Google array in "{nameOut}" generated ! \n')
243                 print("-----")
244
245     if child.match("*plus_critic_sales"):
246         for subchild in child.iterdir():
247             nameOut = "plus_critic_sales/" + subchild.stem + "_array.txt"
248             pathToF = outDir.joinpath(nameOut)
249             if subchild.match("*genre_plat_r.txt"):
250                 with open(subchild,"r",encoding="utf-8") as file, open(pathToF,
251                     "a",encoding="utf8") as out:
252                     results = getResults(file)
253                     for res in results:
254                         name = getTag(res,"name")
255                         platform = getTag(res,"platform")
256                         genre = getTag(res,"genre")
257                         critic = getTag(res,"critic")
258                         row = f'["{name[0]}", "{platform[0]}", "{genre[0]}",
259                             {critic[0]}], '
260                         out.write(row)
261                         out.write("\n")
262                     print(f'Google array in "{nameOut}" generated ! \n')
263                     print("-----")
264
265     if subchild.match("*critic_sales_r.txt"):
266         with open(subchild,"r",encoding="utf-8") as file, open(pathToF,
267             "a",encoding="utf8") as out:

```

```

246         results = getResults(file)
247         out.write('["Titre du jeu", "Ventes mondiales", "Ventes
américaines", "Ventes européennes", "Ventes japonaises"],\n')
248     for res in results:
249         name = getTag(res,"name")
250         platform = getTag(res,"platform")
251         salesglob = getTag(res,"salesglob")
252         salesusa = getTag(res,"salesusa")
253         saleseuro = getTag(res,"saleseuro")
254         salesjap = getTag(res,"salesjap")
255
256         row = f'["{name[0]} ({platform[0]})", {salesglob[0]},
{salesusa[0]}, {saleseuro[0]}, {salesjap[0]}],'
257         out.write(row)
258         out.write("\n")
259     print(f'Google array in "{nameOut}" generated ! \n')
260     print("-----")
261
262     if child.match("*plus_esrb_sales"):
263         for subchild in child.iterdir():
264             nameOut = "plus_esrb_sales/" + subchild.stem + "_array.txt"
265             pathToF = outDir.joinpath(nameOut)
266             simFiles3 = ["esrb_ventes_euro_r", "esrb_ventes_jap_r",
"esrb_ventes_usa_r"]
267             if subchild.stem in simFiles3:
268                 with open(subchild,"r",encoding="utf-8") as file, open(pathToF,
"a",encoding="utf8") as out:
269                     results = getResults(file)
270                     out.write('["Symbole ESRB", "Ventes (en millions)],\n')
271                     for res in results:
272                         esrb = getTag(res,"esrb")
273                         sales = getTag(res,"sales")
274                         row = f'["{esrb[0]}", {sales[0]}],'
275                         out.write(row)
276                         out.write("\n")
277                     print(f'Google array in "{nameOut}" generated ! \n')
278                     print("-----")
279
280             if subchild.match("*jeux_esrb_r.txt"):
281                 with open(subchild,"r",encoding="utf-8") as file, open(pathToF,
"a",encoding="utf8") as out:
282                     results = getResults(file)
283                     out.write('["Symbole ESRB", "Nombre de jeux"],\n')
284                     for res in results:
285                         esrb = getTag(res,"esrb")
286                         count = getTag(res,"count")
287                         row = f'["{esrb[0]}", {count[0]}],'
288                         out.write(row)
289                         out.write("\n")
290                     print(f'Google array in "{nameOut}" generated ! \n')
291                     print("-----")
292
293             simFiles4 = ["top10_ventes_esrb_euro_r", "top10_ventes_esrb_global_r",
"top10_ventes_esrb_jap_r", "top10_ventes_esrb_usa_r"]
294             if subchild.stem in simFiles4:
295                 with open(subchild,"r",encoding="utf-8") as file, open(pathToF,
"a",encoding="utf8") as out:
296                     results = getResults(file)
297                     for res in results:
298                         name = getTag(res,"name")
299                         platform = getTag(res,"platform")
300                         esrb = getTag(res,"esrb")
301                         sales = getTag(res,"sales")
302                         row = f'["{name[0]} ({platform[0]})", "{esrb[0]}",
{sales[0]}],'
303                         out.write(row)
304                         out.write("\n")
305                     print(f'Google array in "{nameOut}" generated ! \n')
306                     print("-----")

```